



Diffusion models

Лекция 1

Generative trilemma



Diffusion



Idea: define forward noising process and try to reverse it

Отшумляем чуть-чуть картинки и добавляем на шум на каждом шаге. У backward цель проинструментировать обратный процесс

КАК ВВЕСТИ процесс ЗАТУХНЕНИЯ

$$x_0 \sim p_{data}; \quad x_t = x_{t-1} + g(t) \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, I)$$

(Variance exploding) нез. с $x_0, \dots, x_{t-1}$

$$x_t = \underbrace{\sqrt{1-\beta_t}}_{const} x_{t-1} + \sqrt{\beta_t} \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, I)$$

нез. с $x_0, \dots, x_{t-1}$

(Variance preserving, VP)

$$\text{Var } x_t = (1-\beta_t) \text{Var } x_{t-1} + \beta_t \cdot I \leftarrow \text{выразим изменение дисперсии}$$

Если сделать предположение:

$\text{Var } x_0 = I \Rightarrow \text{Var } x_t = I, \quad \forall t=0 \dots T$, то есть дисперсия сохраняется
такой подход не "размазывает" распределение

считаем, что фикс., поэтому
без учета от x_t
идем от

$$q_{t|t-1}(x_t | x_{t-1}) = \mathcal{N}(x_t | \sqrt{1-\beta_t} x_{t-1}, \beta_t I)$$

$$q_{t|0}(x_t | x_0) = ?$$

x_t — линейная комбинация
с с.в. ε_t , поэтому то
 x_t тоже нормальна

$$x_t = \underbrace{c_t}_{c_{t-1} x_{t-1} + d_{t-1} \varepsilon_{t-1}} x_{t-1} + d_t \varepsilon_t = c_0 x_0 + \sum_{s=1}^t c_s \varepsilon_s$$

$$q_{t|0}(x_t | x_0) = \mathcal{N}(x_t | ?)$$

$$\begin{aligned} \mathbb{E}_{q_{t|0}(x_t | x_0)} x_t &= \mathbb{E}_{q_{t|0}} \left(\underbrace{\sqrt{1-\beta_t}}_{const} x_{t-1} + \sqrt{\beta_t} \varepsilon_t \right) = \sqrt{1-\beta_t} \mathbb{E}_{q_{t-1|0}}^{x_{t-1}}(x_{t-1} | x_0) = \\ &= \left(\prod_{s=1}^t \sqrt{1-\beta_s} \right) \cdot \mathbb{E}_{q_{1|0}}^{x_0} x_0 = x_0 \cdot \prod_{s=1}^t \sqrt{1-\beta_s} \end{aligned}$$

$$\text{Var}_{q_{t|0}(x_t|x_0)} X_t = (1-\beta_t) \text{Var}_{q_{t-1|0}(x_{t-1}|x_0)} X_{t-1} + \beta_t \cdot I$$

$$\begin{aligned} I - \text{Var}_{q_{t|0}(x_t|x_0)} X_t &= I - \beta_t I - (1-\beta_t) \text{Var}_{q_{t-1|0}(x_{t-1}|x_0)} X_{t-1} = \overset{0}{\text{const}} \\ &= (1-\beta_t) (I - \text{Var}_{q_{t-1|0}(x_{t-1}|x_0)} X_{t-1}) = \dots = \left(\prod_{s=1}^t (1-\beta_s) \right) \cdot (I - \text{Var}_{q_{1|0}} X_0) = \end{aligned}$$

$$= \left(\prod_{s=1}^t (1-\beta_s) \right) \cdot I$$

$$\text{Var}_{q_{t|0}(x_t|x_0)} X_t = I - \left(\prod_{s=1}^t (1-\beta_s) \right) \cdot I = \left(1 - \prod_{s=1}^t (1-\beta_s) \right) \cdot I$$

Умоз:

$$\begin{aligned} \mathbb{E}_{q_{t|0}(x_t|x_0)} X_t &= \left(\prod_{s=1}^t (1-\beta_s) \right) \cdot X_0 \\ &\quad \parallel \\ &\quad \underbrace{\quad}_{d_t} \cdot X_0 \end{aligned} \quad \begin{aligned} \text{Var}_{q_{t|0}(x_t|x_0)} X_t &= \left(1 - \prod_{s=1}^t (1-\beta_s) \right) \cdot I \\ &\quad \parallel \\ &\quad (1-d_t) \cdot I \end{aligned}$$

$$d_t = \prod_{s=1}^t (1-\beta_s)$$

$$q_{t|0}(x_t|x_0) = \mathcal{N}\left(x_t \mid \overset{0}{\nearrow} d_t X_0, \overset{1}{\nearrow} (1-d_t) I\right)$$

$$q_{T|0}(x_T|x_0) \approx \mathcal{N}(x_T \mid 0, I)$$


$$(\text{берём } T, \beta_t: \prod_{s=1}^T (1-\beta_s) \approx 0)$$

$$q_T(x_T) = \int \underbrace{q_{T|0}(x_T|x_0) q_0(x_0)}_{q_{0,T}(x_0, x_T)} dx_0 \approx$$

$$P(A_i) = \sum_{A_j} P(A_i, A_j) P(A_j)$$

$$\approx \int \mathcal{N}(x_T | 0, I) q_0(x_0) dx_0 = \mathcal{N}(x_T | 0, I)$$

Пример




Левые точки скорее перейдут в левую моду, правая — в правую. Крутость диффузиона в такой равномерной покрывающей.

Как обратить процесс?

$$q_{t+1:t}(x_t|x_{t+1}) = \mathcal{N}(x_t | \sqrt{1-\beta_t} x_{t+1}, \beta_t I)$$

$$q_{t|0}(x_t|x_0) = \mathcal{N}(x_t | \sqrt{\alpha_t} x_0, (1-\alpha_t) I)$$

$$q_{t+1:t}(x_T \sim \mathcal{N}(0, I) \quad x_{t+1} \sim q_{t+1:t}(x_{t+1}|x_T))$$




$$q_{t-1|t}(x_{t-1}|x_t) = \frac{\overset{\text{прямое}}{q_{t|t-1}(x_t|x_{t-1})} q_{t-1}(x_{t-1})}{q_t(x_t)}$$

$$q_t(x_t) = \int \underset{\text{прямое}}{q_{t|0}(x_t|x_0)} \underset{\text{сложно}}{p_{\text{data}}(x_0)} dx_0$$

$$\frac{p(x_{t+1})p(x_t)}{p(x_t)}$$

Diagram showing a node x_t connected to x_{t+1} with a red arrow pointing from x_t to x_{t+1} .



$q_{t-1:t}(x_{t-1}|x_t)$ — сложн. распр. $\Rightarrow$ моделируем нейронкой

θ ← параметры нейронки

$$p_{t:t+1}(x_{t+1}|x_t) = \mathcal{N}(x_{t+1} | \mu_t^\theta(x_t), \sigma_t^2 I)$$

↑
нейронка

То есть переход $t \rightarrow t+1$, это норм. распр. с центром, который предсказывает нейронка, и к-ой дисперсией

$$x_T \sim \mathcal{N}(0, I) \quad x_{t-1} = \mu_t^\theta(x_t) + \underbrace{\epsilon_t \sigma_t}_{\mathcal{N}(0, \sigma_t^2 I)} \quad \epsilon_t \sim \mathcal{N}(0, I)$$

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t$$

$x_0 \sim p_{data}$

Forward



p_{data}

Backward

$$x_{t-1} = \mu_t^\theta(x_t) + \sigma_t \cdot \hat{\epsilon}_t$$

$\mathcal{N}(0, \sigma^2)$

$x_T \sim \mathcal{N}(0, I)$

$$q_{0:t-1, t+1, \dots, T}(x_0, \dots, x_t) = q_0(x_0) \cdot q_{1:0}(x_1|x_0) \cdot q_{t:1}(x_t|x_1) \cdot \dots$$

Forward: $q_{0:T}(x_0, \dots, x_T) = \underbrace{q_0(x_0)}_{\substack{\text{исходное} \\ \text{правило} \\ \text{марковости}}} \cdot \prod_{t=1}^T \underbrace{q_{t:t-1}(x_t|x_{t-1})}_{\substack{\text{марков. цепь}}}$

Backward: $p_{0:T}^\theta = \mathcal{N}(x_T | 0, I) \cdot \prod_{t=1}^T p_{t:t+1}^\theta(x_{t+1}|x_t)$

↑
марк. цепь


$$KL \left(q_{0:T}(x_0, \dots, x_T) \parallel p_{0:T}^{\theta}(x_0, \dots, x_T) \right) \rightarrow \min_{\theta}$$

совместные распр. на весь процесс

KL-дивергенция — метрика, показывающая, насколько плохо одно распр. вероятности аппроксимирует другое распр.

$$= \mathbb{E}_{q_{0:T}(x_0, \dots, x_T)} \log \frac{q_{0:T}(x_0, \dots, x_T)}{p_{0:T}^{\theta}(x_0, \dots, x_T)}$$



Model and Training



$$q_{t:t+1} = \frac{q_{t:t+1} \cdot q_{t-1}}{q_t} \rightarrow q_{t:t+1,0} = \frac{q_{t:t+1} \cdot q_{t+1|0}}{q_{t|0}}$$

↑
"предсказать чуть менее шумную собачку, по шумной собачке и собачке"

уже лезло, считаем



$$KL \left(q_{0:T}(x_0, \dots, x_T) \parallel p_{0:T}^{\theta}(x_0, \dots, x_T) \right) \rightarrow \min_{\theta}$$

совместные распредел. на весь процесс

$$\mathbb{E}_{q_{0:T}(x_0, \dots, x_T)} \log \frac{q_{0:T}(x_0, \dots, x_T)}{p_{0:T}^{\theta}(x_0, \dots, x_T)} = \mathbb{E}_{q_{0:T}} \log \frac{q_T(x_T) \prod_{t=1}^T q_{t-1:t}(x_{t-1}|x_t)}{p_T(x_T|0, \mathbf{I}) \prod_{t=1}^T p_{t-1:t}^{\theta}(x_{t-1}|x_t)}$$

$$= \mathbb{E}_{q_{0:T}} \log \frac{q_0(x_0) q_{T|0}(x_T|x_0) \prod_{t=2}^T q_{t-1|t_0}(x_{t-1}|x_t, x_0)}{\mathcal{N}(x_T|0, \hat{I}) \cdot p_{\theta_1}^{\theta}(x_0|x_1) \cdot \prod_{t=2}^T p_{t-1|t}^{\theta}(x_{t-1}|x_t)}$$

$$0 \rightarrow T \rightarrow T-1 \rightarrow \dots$$

$$g_{0:T} = g_0(x_0) \cdot g_{T|0}(x_T|x_0) \cdot g_{T-1|T,0}(x_{T-1}|x_T, x_0) \cdot \dots$$

||

$$g_T(x_0) \cdot g_{T-1|T}(x_{T-1}|x_T) \cdot g_{T-2|T-1,T}(x_{T-2}|x_{T-1}, x_T) \cdot \dots$$

$$T \rightarrow T-1 \rightarrow T-2 \rightarrow \dots$$

$$\underset{\substack{\text{за счет} \\ \text{шарковости}}}{g_{T-2|T-1}(x_{T-2}|x_{T-1})}$$

То есть просто перенесли
порядок сжатия в
цепном правиле

Великан 1

Sampling

$$\mathbb{E}_{q_{0:T}} \log \frac{\cancel{q_0(x_0)} \cancel{q_{T-1}(x_{T-1}|x_T)} \prod_{t=2}^T q_{t-1|t,0}(x_{t-1}|x_t, x_0)}{\cancel{\mathcal{N}(x_{T-1}|0, I)} \cancel{p_{\theta_1}(x_0|x_1)} \prod_{t=2}^T p_{\theta_{t-1}}^{\theta}(x_{t-1}|x_t)}$$

не будем, потому что
связан с p_{θ}

не сильно влияет
если много итераций

$\rightarrow \min_{\theta}$

всё что не зависит от θ можем выкинуть
не влияет на минимизируемую функцию

$$p_{\theta_1}^{\theta}(x_0|x_1) \approx S_{x_1}(x_0)$$

можно пренебречь

$$\approx \mathbb{E}_{q_{0:T}(x_0 \dots x_T)} \log \frac{\prod_{t=2}^T q_{t-1|t,0}(x_{t-1}|x_t, x_0)}{\prod_{t=2}^T p_{t-1|t}^{\theta}(x_{t-1}|x_t)} =$$

$$= \sum_{t=2}^T \mathbb{E}_{q_{0:T}(x_0 \dots x_t)} \log \frac{q_{t-1|t,0}(x_{t-1}|x_t, x_0)}{p_{t-1|t}^{\theta}(x_{t-1}|x_t)} =$$

$$\mathbb{E}_{p(x)} \log \frac{p(x)}{q(x)} = KL(p(x) || q(x))$$

$$\mathbb{E}_{p(x,y,z)} \log \frac{p(x,y,z)}{q(x,y,z)} = KL(p(x,y,z) || q(x,y,z))$$

$$= \sum_{t=2}^T \mathbb{E}_{q_{0,t-1|t}(x_0, x_{t-1}|x_t)} \log \frac{q_{t-1|t,0}(x_{t-1}|x_t, x_0)}{p_{t-1|t}^{\theta}(x_{t-1}|x_t)} =$$

$$= \sum_{t=2}^T \mathbb{E}_{q_{0,t}(x_0, x_t)} \mathbb{E}_{q_{t-1|0,t}(x_{t-1}|x_0, x_t)} \log \frac{q_{t-1|t,0}(x_{t-1}|x_t, x_0)}{p_{t-1|t}^{\theta}(x_{t-1}|x_t)} =$$

$\int \int p(x_0, x_t) \cdot \frac{q(x_0, x_t, x_{t-1})}{q(x_0, x_t) \cdot q(x_{t-1}|x_0, x_t)}$

$$= \sum_{t=2}^T \mathbb{E}_{q_{0,t}(x_0, x_t)} \cdot KL \left(\underbrace{q_{t-1|t,0}(x_{t-1}|x_t, x_0)}_{\text{это уже можно считать}} || p_{t-1|t}^{\theta}(x_{t-1}|x_t) \right)$$

$$p_{t-1|t}^{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1} | \mu_t^{\theta}(x_t), \sigma_t^2 I)$$

$$q_{t-1|t,0}(x_{t-1}|x_t, x_0) = \frac{q_{t|t-1}(x_t|x_{t-1}) q_{t-1|0}(x_{t-1}|x_0)}{x_{t|0}(x_t|x_0)}$$

$$q_{t|t-1} = \mathcal{N}(x_t | \sqrt{1-\beta_t} x_{t-1}, \beta_t I)$$

$$q_{t|0} = \mathcal{N}(x_t | \sqrt{d_t} x_0, (1-d_t) I)$$

$$q_{t-1|0} = \mathcal{N}(x_{t-1} | \sqrt{d_{t-1}} x_0, (1-d_{t-1}) I)$$

$$\begin{aligned} \mathcal{N}(z | \mu, \sigma^2 I) &= \frac{1}{(\sigma^2 I)^{D/2}} \cdot \exp\left(-\frac{1}{\sigma^2} \|z - \mu\|^2\right) = \\ &= \text{const} \cdot \exp(-\text{кв. ф-я}(z, \mu)) \longleftarrow \exp(\cap) \end{aligned}$$

$$q_{t-1|t,0}(x_{t-1} | x_t, x_0) =$$

$$\frac{\exp(-\text{кв.}(x_{t-1}, x_t)) \exp(-\text{кв.}(x_{t-1}, x_0))}{\exp(-\text{кв.}(x_t, x_0))} =$$

$$= \text{const} \cdot \exp(-\text{кв.}(x_{t-1}, x_t, x_0)) = \left[\text{можно вывести} \right] =$$

считаем кв. отнсл. x_{t-1}

$$= \mathcal{N}(x_{t-1} | \underbrace{A_t x_t + B_t x_0}_{A_t \text{ "шумный котик" + } B_t \text{ "чистый котик"}}, C_t^2 I)$$

A_t "шумный котик" + B_t "чистый котик"

$$= \sum_{t=2}^T \mathbb{E}_{q_{0:t}}(x_0, x_t) \cdot \underbrace{KL(q_{t-1:t,0}(x_{t-1}|x_{t,0}) \| p_{t-1:t}^\theta(x_{t-1}|x_t))}_{\text{это тоже можно считать}} \quad \text{---}$$

$$p_{t-1:t}^\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1} | \mu_t^\theta(x_t), \sigma_t^2 I)$$

$$q_{t-1:t,0}(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1} | A_t x_t + B_t x_0, C_t^2 I)$$

ыв

Если $\hat{x} \sim \mathcal{N}(\mu_1, \sigma_1^2 I)$, $\hat{y} \sim \mathcal{N}(\mu_2, \sigma_2^2 I)$,
то $KL(p_1 \| p_2) = c \cdot \|\mu_1 - \mu_2\|^2 + \text{dist}(\sigma_1, \sigma_2)$

по факту изберем
расстояние между распределениями

Для удобства всегда $\text{dist}(\sigma_1, \sigma_2) = 0$, т.е. $\sigma_t = C_t$

$$\text{---} \sum_{t=2}^T \mathbb{E}_{q_{0:t}(x_0, x_t)} w_t \|\mu_t^\theta(x_t) - (A_t x_t + B_t x_0)\|^2 \text{---}$$

получается нормальная предсказка или корр.,


а т.к. x_t известно, то фактически цель предсказ. исходное изображение x_0 по x_t

$$\left[\mu_t^\theta(x_t) = A_t x_t + B_t D_t^\theta(x_t) \right] =$$

$$\text{---} \sum_{t=2}^T \mathbb{E}_{q_{0:t}(x_0, x_t)} \hat{w}_t \|D_t^\theta(x_t) - x_0\|^2 \rightarrow \min_{\theta}$$

$$p_{\text{data}}(x_0) q_{t|0}(x_t|x_0)$$

По архитектуре
делают одну нейронку



План обучения: batch-size B

- $x_0^{(1)} \dots x_0^{(B)} \sim p_{\text{data}}$

- $t^{(1)} \dots t^{(B)} \sim \text{семпл. мом. времени}$
($u_1, \dots, T_1$)

- $\epsilon^{(1)} \dots \epsilon^{(B)} \sim \text{нез. } \mathcal{N}(0, I)$

- $\alpha^{(1)} \dots \alpha^{(B)} : \alpha^{(i)} = \alpha_{t^{(i)}} = \prod_{s=1}^{t^{(i)}} (1 - \beta_s)$

$$\beta \quad \boxed{\phantom{\text{array}}}$$

$$\alpha \rightarrow (1 - \beta) \cdot \text{cumprod}$$

- $x_{\text{noisy}}^{(i)} = \sqrt{\alpha^{(i)}} x_0^{(i)} + \sqrt{1 - \alpha^{(i)}} \epsilon^{(i)}$

- $\frac{1}{B} \sum_{i=1}^B \| D_{t^{(i)}}^{\theta}(x_{\text{noisy}}^{(i)}) - x_0^{(i)} \|^2 \cdot \text{backward}()$

$$x_T \sim \mathcal{N}(0, I)$$

$$x_{t-1} \sim p_{t-1:t}^{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1} | \mu_t^{\theta}(x_t), C_t^{\theta} I)$$


$$A_t x_t + B_t D_t^{\theta}(x_t)$$

$$x_{t-1} = A_t x_t + B_t \underbrace{D_t^{\theta}(x_t)}_{\text{предсказание } x_0}$$

То есть генератор кучки
гиз вот этого перехода

DDPM

$$x_{t-1} \leftarrow x_t$$



$$D(x_t)$$

$$\sum_{t=0}^T \mathbb{E}_{q_{0,t}(x_0, x_t)} w_t \|D_t^\theta(x_t) - x_0\|^2 \in$$

$$x_t = \sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon$$

$$q_{0,t}(x_0, x_t) = q_0(x_0) \cdot \mathcal{N}(\epsilon | 0, I)$$

$x_t =$

$$\in \sum_{t=0}^T \mathbb{E}_{q_0(x_0) \mathcal{N}(\epsilon | 0, I)} \|D_t^\theta(\sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon) - x_0\|^2 \in$$

$$x_0 = \frac{x_t - \sqrt{1-d_t} \epsilon}{\sqrt{d_t}}$$

$$\in \sum_t \mathbb{E}_{q_0(x_0) \mathcal{N}(\epsilon | 0, I)} \|D_t^\theta(\sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon) - x_0\|^2 =$$

$$= \sum_t \mathbb{E}_{q_0(x_0) \mathcal{N}(\epsilon | 0, I)} \|D_t^\theta(x_t) - \frac{x_t - \sqrt{1-d_t} \epsilon}{\sqrt{d_t}}\|^2 \in$$

$$D_t^\theta(x_t) = \frac{x_t - \sqrt{1-d_t} \epsilon_t^\theta(x_t)}{\sqrt{d_t}}$$

$$\in \sum_t \mathbb{E}_{q_0(x_0) \mathcal{N}(\epsilon | 0, I)} \hat{w}_t \|\epsilon_t^\theta(\sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon) - \epsilon\|^2$$

$$L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{q_0(x_0) \mathcal{N}(\epsilon | 0, I)} \|\epsilon_t^\theta(\sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon) - \epsilon\|^2$$