

Лекция 2.

С прошлой лекции

$$q_{0:T}(x_0 \dots x_T) = p_{data}(x_0) \prod_{t=1}^T q_{t|t-1}(x_t | x_{t-1})$$

$$q_{t|t-1} = \mathcal{N}(x_t | \sqrt{1-\beta_t} x_{t-1}, \beta_t I)$$

$$q_{0:t_0}(x_t | x_0) = \mathcal{N}(x_t | \sqrt{\alpha_t} x_0, (1-\alpha_t) I)$$

$$\alpha_t = \prod_{s=1}^t (1-\beta_s) \rightarrow 0$$

$$p_{0:T}^{\theta}(x_0, \dots, x_T) = \mathcal{N}(x_T | 0, I) \prod_{t=1}^T \underbrace{p_{t-1|t}^{\theta}(x_{t-1} | x_t)}_{\mathcal{N}(x_{t-1} | A_t x_t + B_t D_t^{\theta}(x_t), c_t^2 I)}$$

$$KL(q_{0:T}(x_0 \dots x_T) \| p_{0:T}^{\theta}(x_0 \dots x_T)) \rightarrow \min_{\theta}$$

и

$$\text{const} + \sum_{t=2}^T \mathbb{E}_{q_{0:t}(x_0, x_t)} KL(q_{t-1|t, x_0}(x_{t-1} | x_t, x_0) \| p_{t-1|t}^{\theta}(x_{t-1} | x_t)) =$$

$$= \sum_{t=2}^T w_t \cdot \mathbb{E}_{q_{0:t}(x_0, x_t)} \| D_t^{\theta}(x_t) - x_0 \|^2 \rightarrow \min_{\theta}$$

$$x_0^{(1)} \dots x_0^{(b)} \sim \text{dataset}$$

$$t^{(1)} \dots t^{(b)} \sim \text{распр. на } \{1 \dots T\}$$

$$e^{(1)} \dots e^{(b)} \sim \mathcal{N}(0, I)$$

$$x_{noisy}^{(i)} = \sqrt{\alpha_t^{(i)}} x_0^{(i)} + \sqrt{1-\alpha_t^{(i)}} e^{(i)}$$

$$\frac{1}{B} \sum_{i=1}^B \| D_{t_i}^{\theta}(x_{noisy}^{(i)}) - x_0^{(i)} \|^2. \text{ backward}$$

$$p_{t-1|t}^{\theta}(x_{t-1}, x_t) = \mathcal{N}(x_{t-1} | A_t x_t + B_t D_t^{\theta}(x_t), c_t^2 I)$$

Семплер: $x_T \sim \mathcal{N}(0, I)$
 $x_{t-1} = A_t x_t + B_t D_t^{\theta}(x_t) + c_t e_t$
 $A_t \nearrow B_t \searrow$

Парам: $T, \beta_1, \dots, \beta_T \rightarrow \alpha_1, \dots, \alpha_T$

$$\beta_1, \dots, \beta_T \quad d_1, \dots, d_T$$

$$\hat{\beta}_1, \dots, \hat{\beta}_T \quad \hat{d}_1, \dots, \hat{d}_T$$

$$\mathbb{E} \| D^\theta(\sqrt{d_t} X_0 + \sqrt{1-d_t} \epsilon) - X_0 \|^2$$

$$\mathbb{E} \| D^\varphi(\sqrt{d_s} X_0 + \sqrt{1-d_s} \epsilon) - X_0 \|^2$$

$$\sqrt{d_t} X_0 + \sqrt{1-d_t} \epsilon$$

$$\hat{\parallel} \sqrt{\frac{1-d_t}{d_t}} \epsilon = b$$

$$X_0 + \sqrt{\frac{1-d_t}{d_t}} \epsilon$$

$$X_0 + \sqrt{\frac{1-d_s}{d_s}} \epsilon$$

Есть ли такой s : $\hat{\parallel} = b$?

Тогда одну нейронку можно использовать вместо группы

То есть если обучили на 1000 шагов, то можно использовать и для генерации на 100

$$\text{Цель: } \sim q_0(x_0) \longrightarrow q_0(x_0|y)$$

$$q_{0:T}(x_0, \dots, x_T|y) = q_0(x_0|y) \prod_t q_{t|t-1}(x_t|x_{t-1}).$$


Отфильтр. зависит от объектов удовлетв. условию

Обучение для услов. распр.:

$$\sum_{t=0}^T w_t \mathbb{E}_{q_{0:t}(x_0, x_t|y)} \| D^\theta(x_t|y) - x_0 \|^2$$

$$\text{Семпл.: } x_T \sim \mathcal{N}(0, I) \quad x_{t-1} = A_t x_t + B_t D_t^\theta(x_t|y) + C_t \epsilon_t$$

Раньше:



что-то среднее генерит

$$x \sim \text{batch } D_t(x_t)$$



меньше неопределённости

$x, y \sim \text{batch}$
 $D_t(x_t|y)$

3

3

Хотелось бы: понять, как устроен $(q_{t-1:t})$

просто

$$q_{t-1:t}(x_{t-1}|x_t) = \frac{q_{t:t-1}(x_t|x_{t-1}) q_{t-1}(x_{t-1})}{q_t(x_t)} =$$

$$= q_{t:t-1}(x_t|x_{t-1}) \exp(\log q_{t-1}(x_{t-1}) - \log q_t(x_t)) \approx$$

$$\approx q_{t:t-1}(x_t|x_{t-1}) \exp(\log q_t(x_{t-1}) - \log q_t(x_t)) =$$

$$= q_{t:t-1}(x_t|x_{t-1}) \exp(\underbrace{\langle \nabla \log q_t(x_t), x_{t-1} - x_t \rangle + o(x_{t-1} - x_t)}_{\text{score функция распр. } q_t(x_t)})$$

score функция
распр. $q_t(x_t)$

$$q_t(x_t) = \int q_{0,t}(x_0, x_t) dx_0 = \int \underbrace{q_{t|0}(x_t|x_0)}_{\text{просто}} \underbrace{q_0(x_0)}_{\text{сложно}} dx_0$$

$$\nabla \log q_t(x_t) =$$

$$= \frac{\nabla_{x_t} q_t(x_t)}{q_t(x_t)} = \frac{\nabla_{x_t} \int q_{t|0}(x_t|x_0) q_0(x_0) dx_0}{q_t(x_t)} =$$

$$= \frac{\int \nabla_{x_t} q_{t|0}(x_t|x_0) q_0(x_0) dx_0}{q_t(x_t)} =$$

$$= \frac{\int \nabla_{x_t} \log q_{t|0}(x_t|x_0) q_{t|0}(x_t|x_0) q_0(x_0) dx_0}{q_t(x_t)} =$$

$$= \int \left(\nabla_{x_t} \log q_{t|0}(x_t|x_0) \right) \cdot q_{0,t}(x_0|x_t) dx_0 = \mathbb{E}_{q_{0,t}(x_0|x_t)} \nabla \log q_{t|0}(x_t|x_0)$$

скор. q_0 -а прост. распр. $\downarrow$

$q_{0,t}(x_0|x_t)$

$\nabla \log q_{t|0}(x_t|x_0)$ $\nwarrow$ сложн. распр.

$$\nabla_{x_t} \log q_t(x_t) = \mathbb{E}_{q_{0,t}(x_0|x_t)} \nabla \log q_{t|0}(x_t|x_0)$$

Рассмотрим простой случай


$$q_0(x_0) = \frac{1}{3} \sum_{i=1}^3 \delta(x_0 = x^{(i)})$$

$$q_{t|0}(x_t|x_0) = \mathcal{N}(x_t|x_0, \sigma_t^2 I)$$

для удобства без
масштабирования

$$q_t(x_t) = \sum_{i=1}^3 q_{t|0}(x_t|x^{(i)}) q_0(x^{(i)}) =$$

$$= \sum_{i=1}^3 \frac{1}{3} \mathcal{N}(x_t|x^{(i)}, \sigma_t^2 I)$$



$$\nabla_{x_t} \log q_t(x_t) = \sum_{i=1}^3 q_{0|t}(x^{(i)}|x_t) \cdot \nabla \log q_{t|0}(x_t|x^{(i)})$$

↓ куда двигаться, чтобы плотность ↑
 $\nabla_{x_t} \log q_t = E_{q_{t|0}} \nabla \log q_{t|0}$


score ф-я смеси гаусси — это сумма score ф-ий отд. гаусси, взвеш. пропорционально апостериорной вер-ти, что пришли из данной компоненты

вер. апостериорная $\propto$ плотность $0 \rightarrow t$
 $x^{(i)} \rightarrow x_t$

$$q_{0|t}(x^{(i)}|x_t) \propto q_{t|0}(x_t|x^{(i)}) \cdot \frac{1}{3} \propto \frac{1}{3} \exp\left(-\frac{1}{2\sigma_t^2} \|x_t - x^{(i)}\|^2\right)$$

$$\left(\frac{q_{t|0}(x_t|x^{(i)}) \cdot \frac{1}{3}}{q_t(x_t)} \right)$$

const нормир. константа



То есть по итогу score показывает как max плотность смеси гаусси: напр. в сторону центра гауссиа x вер-ть, что пришли из данной гаусси

$$\nabla \log q_t(x_t) = E_{q_{0|t}(x_0|x_t)} \nabla \log q_{t|0}(x_t|x_0)$$

$$q_{t|0}(x_t|x_0) = \mathcal{N}(x_t | \sqrt{d_t} x_0, (1-d_t) I) =$$

$$= \text{const} \cdot \exp\left(\frac{-1}{2(1-d_t)} \|x_t - \sqrt{d_t} x_0\|^2\right)$$

$$\nabla_{x_t} \log q_{t|0}(x_t/x_0) = \nabla_{x_t} \left(-\frac{1}{2(1-d_t)} \|x_t - \sqrt{d_t} x_0\|^2 \right) =$$

$$= -\frac{1}{2(1-d_t)} 2(x_t - \sqrt{d_t} x_0) = \frac{\sqrt{d_t} x_0 - x_t}{1-d_t}$$

$$\nabla_{x_t} \log q_t(x_t) = \mathbb{E}_{q_{0:t}(x_0|x_t)} \nabla \log q_{t|0}(x_t/x_0) =$$

$$= \mathbb{E}_{q_{0:t}(x_0|x_t)} \frac{\sqrt{d_t} x_0 - x_t}{1-d_t} = \frac{\sqrt{d_t} (\mathbb{E}_{q_{0:t}} x_0) - x_t}{1-d_t}$$

аппроксимация x_0 по x_t
по факту наш генератор

Лемма 2

$$\sum_t \mathbb{E}_{q_t(x_t)} \|d_t^\varphi(x_t) - \mathbb{E}_{q_{0:t}(x_0|x_t)} x_0\|^2 =$$

↑ пытаемся возмучить

$$= \sum_t \mathbb{E}_{q_t(x_t)} \left(\|d_t^\varphi(x_t)\|^2 - 2 \langle d_t^\varphi(x_t), \mathbb{E}_{q_{0:t}(x_0|x_t)} x_0 \rangle \right) + \text{const} =$$

не зависит от φ
↓

$$= \text{const} + \sum_t \mathbb{E}_{q_t(x_t)} \|d_t^\varphi(x_t)\|^2 - 2 \sum_t \mathbb{E}_{q_t(x_t)} \langle d_t^\varphi(x_t), \mathbb{E}_{q_{0:t}(x_0|x_t)} x_0 \rangle \quad (\equiv)$$

$$\mathbb{E}_{q_t(x_t)} \langle d_t^\varphi(x_t), \mathbb{E}_{q_{0:t}(x_0|x_t)} x_0 \rangle = \mathbb{E}_{q_t(x_t)} \mathbb{E}_{q_{0:t}(x_0|x_t)} \langle d_t^\varphi(x_t), x_0 \rangle =$$

↑

$$\sum_{i=1}^n \dots \sum_{j=1}^n$$

$$= \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} \langle d_t^\varphi(x_t), x_0 \rangle$$

$$\mathbb{E}_{g_{\cdot,t}} \|x_0\|^2 - \text{const}$$

можно год. и вчетверо

$$\Leftrightarrow \text{const} + \sum_t \left(\mathbb{E}_{g_{\cdot,t}(x_0, x_t)} \|d_t^\varphi(x_t)\|^2 - 2 \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} \langle d_t^\varphi(x_t), x_0 \rangle \right) =$$

гроб. и, итого не считаем

$$= \text{const} + \sum_t \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} \|d_t^\varphi(x_t) - x_0\|^2$$

$\Leftrightarrow$ обучение генератора $D_t^\theta(x_t)$

$$\sum_t \mathbb{E}_{g_t(x_t)} \|d_t^\varphi(x_t) - \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} x_0\|^2 = \text{const} + \sum_t \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} \|d_t^\varphi(x_t) - x_0\|^2$$


$\Leftrightarrow$ в точке оптимума исходного генератора $D_t^\theta(x_t)$:

$$D_t^*(x_t) = \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} x_0$$

$$g_{t-1:t} \Leftrightarrow \nabla \log g_t(x_t) \Leftrightarrow \mathbb{E}_{g_{\cdot,t}(x_0, x_t)} x_0 \Leftrightarrow \sum_t \mathbb{E} \|D_t^\theta(x_t) - x_0\|^2$$

$\searrow \min_\theta$

ещё одним способом прийти к такой функции $\uparrow$



Благодаря сделанному выводу можем манипулировать распре-ми.
 Это св-ва к преобр. с score ф-ми

①

$$\sum_t \mathbb{E}_{q_{t,t}(x_t, x_0)} \left\| D_t^\theta(x_t) - x_0 \right\|^2 \rightarrow D_t^*(x_t) = \mathbb{E}_{q_{t,t}(x_0|x_t)} x_0$$

↓

$$\nabla \log q_t(x_t) = \frac{\sqrt{d_t} D_t^*(x_t) - x_0}{1 - d_t}$$

②

учит score ф-му

$$\sum_t \mathbb{E}_{q_{t,t}(x_t, x_0)} \left\| S_t^\theta(x_t) - \frac{\sqrt{d_t} x_0 - x_t}{1 - d_t} \right\|^2 \rightarrow S_t^*(x_t) = \nabla \log q_t(x_t)$$

$\frac{\sqrt{d_t} D_t^\theta - x_0}{1 - d_t}$

$$x_t = \sqrt{d_t} x_0 + \sqrt{1 - d_t} \epsilon \quad \sqrt{d_t} x_0 - x_t = -\sqrt{1 - d_t} \epsilon$$

$$S_t^\theta(x_t) = - \frac{\epsilon_t^\theta(x_t)}{\sqrt{1 - d_t}}$$

↓

③

$$\sum_t \mathbb{E}_{q_{t,t}(x_t, x_0)} \left\| \epsilon_t^\theta(x_t) - \epsilon \right\|^2 \rightarrow \text{еще один возможный функ-л}$$

$\frac{\sqrt{d_t} x_0 + \sqrt{1 - d_t} \epsilon}{1 - d_t}$

$$\epsilon_t^*(x_t) = \mathbb{E}_{q(\epsilon|x_t)} \epsilon$$

$$\nabla \log q_t(x_t) = \frac{(d_t) D_t^*(x_t) - x_t}{1 - d_t}$$

$$\Downarrow$$

$$D_t^*(x_t) = \frac{(1 - d_t) \nabla \log q_t(x_t) + x_t}{d_t}$$

как получить $\nabla_{x_t} \log q_t(x_t)$?

$$\nabla_{x_t} \log q_t(x_t | y) = \nabla_{x_t} \log \frac{q_t(y | x_t) q_t(x_t)}{q(y)} =$$

двигает в сторону картинок,
в котор. классиф. уверен

$$= \nabla_{x_t} \log q_t(y | x_t) + \nabla_{x_t} \log q_t(x_t)$$

$$\approx \nabla_{x_t} c_t(y | x_t)$$

классиф. картин
noisy classifier
предск. по шумной картинке

$$\text{предоб. генератор}$$

$$\approx s_t^\theta(x_t)$$

$$c_t(y=i | x_t) = \log q_t(y=i | x_t)$$

$$\nabla_{x_t} \log q_t(y | x_t) + \nabla_{x_t} \log q_t(x_t) \leftarrow$$

$\uparrow$
 $(1+\gamma)$
 $\gamma \geq 0$ для большей
уверенности
классиф.

γ - Guidance scale

Classifier $\uparrow$
guidance

Дано: $\nabla_{x_t} \log q_t(x_t)$
Цель: $\nabla_{x_t} \log q_t(y | x_t) + (1+\gamma) \nabla_{x_t} \log q_t(x_t)$

Дано: $\nabla_{x_t} \log q_t(x_t | y)$

Цель: $\nabla_{x_t} \log q_t(x_t) + (1+\gamma) \nabla_{x_t} \log q_t(y | x_t) =$


$$\begin{aligned}
 &= (\nabla_{x_t} \log q_t(x_t) + \nabla_{x_t} \log q_t(y|x_t)) + \gamma \nabla_{x_t} \log q_t(y|x_t) = \\
 &= \nabla_{x_t} \log q_t(x_t|y) + \gamma (\nabla_{x_t} \log q_t(x_t|y) - \nabla_{x_t} \log q_t(x_t)) \approx \\
 &\approx s_t^\theta(x_t|y) + \gamma (s_t^\theta(x_t|y) - s_t^\theta(x_t|\emptyset))
 \end{aligned}$$

Было: $y \in \{1 \dots c\}$ стало: $\hat{y} \in \{1 \dots c, \emptyset\}$

$$(x_i, y_i) \rightarrow (x_i, \hat{y}_i) \quad \hat{y}_i = \begin{cases} y_i & \text{с вер-ю } p \\ \emptyset & \text{с вер-ю } 1-p \end{cases}$$

$$\text{Условие: } \mathbb{E} \sum_t \|D_t^\theta(x_t|\hat{y}) - x_0\|^2$$

classifier-free guidance



Effect of guidance



γ = Guidance scale

Summary

$$KL(q_{0:T} \| p_{0:T}^{\theta}) \rightarrow \min_{\theta}$$

$$\Leftrightarrow \sum_t \mathbb{E}_{q_{0,t}(x_0, x_t)} \|D_t^{\theta}(x_t) - x_0\|^2$$

$\Leftrightarrow$ обучение score ф-ии $\nabla \log q_t(x_t)$

$$\nabla \log q_t(x_t) \xrightarrow{\text{+ классиф.}} \nabla \log q_t(x_t|y)$$



$$\rightarrow \nabla \log q_t(x_t|y) + \gamma (\nabla \log q_t(x_t|y) - \nabla \log q_t(x_t))$$

guidance scale

Детерм. генерация

$$x_{t-1} = A_t x_t + B_t D_t^{\theta}(x_t) + C_t \epsilon_t$$

если заменить на детерминированный шум, то получим детерм. апрос



чтобы имитировать стохастический процесс уменьшения потребности каждой частицы в стирании уменьшения плотности

$$X_{t+1} = A_t X_t + B_t D_t^{\theta}(\kappa_t) + \boxed{C_t \varepsilon_t} - \frac{C_t^2}{2} \nabla \log q_t(\kappa_t)$$