

1 лекция

DL 1 лекция

Вспомогательные ML

$\{x_i, y_i\}_{i=1}^l, x_i \in \mathbb{R}^d, y_i \in \{-1, 1\}$ бинарная классиф.

$y(x) = \text{sign}(w^T x), w \in \mathbb{R}^d$ Логистическая регрессия

$$Q = \sum_{i=1}^l L(x_i, y_i, w) \quad \text{хотим макс. log}$$

$$L(x, y, w) = -\log \sigma(y w^T x) \Leftrightarrow -(y \ln(z) + (1-y) \ln(1-z))$$

$$\sigma(z) = \frac{1}{1 + \exp(-z)}$$

$\{x_i, y_i\}, x_i \in \mathbb{R}^d, y_i \in \{1, \dots, k\}$

$y(z) = \arg \max_{1 \leq k \leq K} (w_k^T x), W \in \mathbb{R}^{K \times d}$


$$Q = \sum_{i=1}^l L(y_i, x_i, w) \quad \text{Softmax}$$

$$L(x, y, w) = -\log \frac{\exp(w_y^T x)}{\sum_{k=1}^K \exp(w_k^T x)} \quad \rightarrow Q \text{ в таком случае каз-ся переопределенной}$$

$$\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z))$$

$$\frac{\partial L}{\partial w} = -\frac{\sigma(y w^T x) / (1 - \sigma(y w^T x))}{\sigma(y w^T x)} \cdot y x = -y x (1 - \sigma(y w^T x))$$

Граф вычислений



$$z = w^T x - \text{логит}$$

$$a = \sigma(z) - \text{вероятность}$$

(a) Вспомогательные ML

Упростим в рамках нашей постановки

$\sigma(x) = \sigma(w, x) - \text{подстановка}$

$$\frac{1}{l} \sum_{i=1}^l (-y_i - 1) \log \frac{1}{1 + \exp(-w, x_i)}$$

$$- [y_i - 1] \log \left(1 - \frac{1}{1 + \exp(-w, x_i)} \right) = \text{преобразовать}$$

$$= \frac{1}{l} \sum_{i=1}^l (y_i - 1) \log (1 + \exp(-w, x_i)) +$$


$$[y_i - 1] \log (1 + \exp(w, x_i)) =$$

$$= \left[\frac{1}{l} \sum_{i=1}^l \log (1 + \exp(-y_i w, x_i)) \right] \rightarrow \text{max}$$

$$L(y, z) = \log (1 + \exp(-y z)) \rightarrow \text{логистическая регрессия}$$

для каждого класса вычисляем log-likelihood

Q-функция




W_1, W_2 - обуч. веса f - нелинейн. ф-я, ф-я активации (например сигмоида)

z_1, a_1 - активации первого слоя z_2, a_2 - активации второго слоя
 (т.к. последний, то считаем и вероятности)


на примере изображений

Искусственные нейроны: если взять вектор, то если z_i с большим весом учитывают x_1 и x_2 , то они "оригиналы" относительно остальных. И так каждый z_i выбирает базовые простейшие признаки. На следующем слое нейроны могут собрать более абстрактную, комплексную информацию, например детектирует фигуру. Следующий слой будет получать что-то уже из этих фигур. И так далее.



ПРИМЕРЫ

ГИПОТЕЗА КОМПАКТНОСТИ





выполнено



не выполнено

Одно и то же. Но при встраивании в вектор абсолютно разные структуры


1. The cat is sleeping on the couch Однородное слово
2. A feline rests upon the sofa Но нет совпад. по словам





Аудиосигнал

Одно слово, но разные графики

Гипотеза компактности — свойство данных, в которых семантически похожие объекты соотв. близкие по метрике вект. представл. (признаковые описания)



гипотеза
выполнена



гипотеза
НЕ выполнена

Нейросети справляются с данными, для которых не выполн. гипотеза компактности, т.к. на каждом слое получают всё более богатые высокоуровн. описания, и на последнем слое получают предств., для которых выполн. гипотеза компакт., с которыми уже справляется линейная регрессия

Алгоритм Forward Pass

- Выход $x \in \mathbb{R}^d$, $y \in \{1 \dots k\}$
- Выход $L \in \mathbb{R}$

1. $a^0 := x$
2. for $i := 1 \dots L$:
3. $z^i := W^i a^{i-1}$ можно просто умножить на вес, так как дано
4. $a^i := f(z^i)$ функция активации
5. $L = \text{Cross Entropy}(a^L, y)$


и-й слой:

$$a^i \in \mathbb{R}^d, z^i \in \mathbb{R}^d$$

$$z^i_k = \langle w^i_k, a^i \rangle$$

$$z^i = \begin{bmatrix} z^i_1 \\ z^i_2 \\ \vdots \\ z^i_n \end{bmatrix} = \begin{bmatrix} \langle w^i_1, a^i \rangle \\ \langle w^i_2, a^i \rangle \\ \vdots \\ \langle w^i_n, a^i \rangle \end{bmatrix} = W^i a^i$$

$$-\log(\text{Softmax})$$



Σ_i - линейн. преобр. с весами W^i , умножает
 f - ф-я активации

CE - кросс энтропия $(-\log(\text{Softmax}(\dots)))$

Пусть $L=1$: $L = \text{CE}(f(Wx))$
 $L=2$: $L = \text{CE}(f(W^2 f(W^1 x)))$

$$W_{\text{new}}^i = W_{\text{old}}^i - \eta \frac{\partial L}{\partial W_{\text{old}}^i}, i = \overline{1, L}$$

$(L=1)$ Пример:

$$\frac{\partial L}{\partial a} = \frac{\partial \text{CE}}{\partial a}$$

$$\frac{\partial L}{\partial z} = \frac{\partial f}{\partial z} \left(\frac{\partial L}{\partial a} \right)$$

$$\frac{\partial L}{\partial w} = \frac{\partial z}{\partial w} \left(\frac{\partial L}{\partial z} \right)$$

Применяется
 правило цепочки

Идем, в отличие
 от основного алгоритма,
 от loss к входу.

Algorithm Backward Pass

- Back $L \leftarrow L-1$
- Back $\frac{\partial L}{\partial w^i}$ for $i=1$

$$1. \frac{\partial L}{\partial a^L} := \frac{\partial CE}{\partial a^L}$$


$$2. \text{for } i=L, L-1, \dots, 2, 1:$$

$$3. \frac{\partial L}{\partial z^i} := \frac{\partial f}{\partial z^i} \frac{\partial L}{\partial a^i}$$


$$4. \frac{\partial L}{\partial w^i} := \frac{\partial \Sigma}{\partial w^i} \frac{\partial L}{\partial z^i}$$

$$5. \frac{\partial L}{\partial a^{i-1}} := \frac{\partial \Sigma}{\partial a^{i-1}} \frac{\partial L}{\partial z^i}$$

$$y = F(x)$$




Forward pass



Backward pass

Все это
реализовано



multi-layer perceptron, MLP

Доказано теоремо, что существует конечная нейронка приближающая любую ф-ю с наперед заданной точностью.

Причины успеха

- авто-фиче-генератор (признаки)
- DL ~ это итер операции, что оптимизировано
- DL ~ это GPU
- DL - это big data
- DL - это autograd (i.e.)

Нейронки тяжело интерпретируются, влияние от ML моделей

~~Сложно~~ Отличительней делать forward и backward не по единичным примерам, а по батчам.

