

Лекция 2. Регуляризация в DL

Градиент в линейном слое:

$$z_i = W_i a_{i-1} \Rightarrow \begin{cases} \nabla_{W_i} L = (\nabla_{z_i} L) a_{i-1}^T \\ \nabla_{a_{i-1}} L = W_i^T (\nabla_{z_i} L) \end{cases}$$

Градиент активации в общем виде:

$$a_i = f(z_i) \Rightarrow \nabla_{z_i} L = (\nabla_{a_i} L) \frac{\partial a_i}{\partial z_i}$$

Формула градиентов на i -ом слое:

$$\begin{aligned} \nabla_{W_i} L &= (\nabla_{z_i} L) a_{i-1}^T = \left((\nabla_{a_i} L) \frac{\partial a_i}{\partial z_i} \right) a_{i-1}^T = \\ &= \left((W_{i+1}^T (\nabla_{z_{i+1}} L)) \frac{\partial a_i}{\partial z_i} \right) a_{i-1}^T = \dots = \left(\prod_{j=i+1}^L W_j^T \right) (\nabla_{a_L} L) \left(\prod_{j=i+1}^L \frac{\partial a_j}{\partial z_j} \right) a_{i-1}^T \end{aligned}$$

Проаксимизируем норму градиента:

$$\| \nabla_{W_i} L \| \leq \left(\prod_{j=i+1}^L \| W_j \| \right) \left(\prod_{j=i+1}^L \left\| \frac{\partial a_j}{\partial z_j} \right\| \right) \| a_{i-1} \|^2$$

Если $a_i = f(z_i)$ — сигмоида:

$$\begin{cases} \frac{\partial a_i}{\partial z_j} = a_i(1-a_i) \\ 0 < a_i < 1 \end{cases} \Rightarrow 0 < \left\| \frac{\partial a_j}{\partial z_j} \right\| < 1 \Rightarrow \prod_{j=i+1}^L \left\| \frac{\partial a_j}{\partial z_j} \right\| \xrightarrow{L \rightarrow \infty} 0$$

• Вывод: во время оптимизации веса первых слоёв будут меняться медленней, чем веса последних слоёв (затухание градиентов)

Функции активации

Их правильный выбор один из способов борьбы с затуханием.

Функция	Затухание	Тождество	Гладкость	Сложность
$\sigma(z) = \frac{1}{1 + e^{-z}}$	FAIL	FAIL	OK	FAIL
$\tanh(z) = 2\sigma(2z) - 1$	FAIL	OK	OK	FAIL
$\text{ReLU}(z) = \max\{0, z\}$	OK	FAIL	OK/FAIL	OK
$\text{LeakyReLU}(z) = \begin{cases} z, & z \geq 0, \\ \alpha z, & \text{otherwise,} \end{cases}$	OK	OK	OK/FAIL	OK
$\text{ELU}(z) = \begin{cases} z, & z \geq 0, \\ e^z - 1, & \text{otherwise.} \end{cases}$	OK	OK	OK	FAIL
$\text{GELU}(z) = z \cdot \Phi(z)$	OK	OK	OK	FAIL
$\text{Swish}(z) = z \cdot \sigma(z)$	OK	OK	OK	FAIL
$\text{Mish}(z) = z \cdot \tanh(\text{softplus}(z))$	OK	OK	OK	FAIL
$\text{ReLU6}(z) = \min(\max(0, z), 6)$	OK	FAIL	OK/FAIL	OK

Тождеств. преобраз.

У сигмоиды: $\sigma: \mathbb{R} \rightarrow [0, 1] \Rightarrow$ нельзя научить тожд. преобраз.

Вычисл. сложность.


Сложные функции счит. через ряды Тейлора ($\exp, \log, e^{\dots}$).

ReLU выгодней σ в этом плане


Гладкость:

гладкость — произв. явл.-ся кепр. ф-ей. Для таких ф-й методы оптим. св-ся быстрее. Для ReLU, LeakyReLU наруш. лишь в 1 точке

Нормализация



Поэтому для б.жел-но, чтобы входы были около нуля. На самом деле жел-но для любой активации



В МО:

1. выбор. среднее и дисп. $\forall$ разг. по батчу:

$$\bar{\mu}_j = \frac{1}{B} \sum_{i=1}^B a_{ij} \quad \bar{\sigma}_j^2 = \frac{1}{B} \sum_{i=1}^B (a_{ij} - \bar{\mu}_j)^2 \quad j = \overline{1, d}$$

2. Нормализуем:

$$\tilde{a}_{ij} = \frac{a_{ij} - \bar{\mu}_j}{\underbrace{\bar{\sigma}_j + \epsilon}_{\text{чтобы } \neq 0}}, \quad i = \overline{1, B}, \quad j = \overline{1, d}, \quad \epsilon > 0$$

Батч не велик $\Rightarrow$ оценки не точные $\Rightarrow$ использовать скользя. среднее:
 $j = \overline{1, d}$:

0. $\hat{\mu}_j = 0, \hat{\sigma}_j = 1$

1. считаем $\bar{\mu}_j, \bar{\sigma}_j$ на батче

2. Обновляем статистики (как правило $\alpha = 0.9$):

$$\hat{\mu}_j := \alpha \bar{\mu}_j + (1 - \alpha) \hat{\mu}_j$$

$$\hat{\sigma}_j^2 := \alpha \bar{\sigma}_j^2 + (1 - \alpha) \hat{\sigma}_j^2$$

3. Нормализуем

4. $\hat{a}_{ij} = \gamma_i \hat{a}_{ij} + \delta_j$

$\gamma_i, \delta_j \in \mathbb{R}$ - обучаемые параметры

Получили Batch Norm

- обуч. преобр. вносит коррект. в "искажение", вносимое нормализ.
- возм. то же преобр.

Борется с затуханием благодаря насыщен. ф-и активаций

Layer pool - тоже самое, только не вдоль размер. B , а вдоль d

Инициализация весов

$$\left(\prod_{j=1}^L \|W_j\| \right) \left(\prod_{j=1}^L \left\| \frac{\partial a_j}{\partial z_j} \right\| \right) \|a_{i-1}\|$$

- очень маленькие - затухают
- большие - взрываются

Xavier Glorot

$$z = Wx, \quad W \in \mathbb{R}^{n_{in} \times n_{out}}, \quad L'_x = W^T L'_z$$

Предположим: $x_i \stackrel{iid}{\sim} \mathcal{N}(0, \text{Var}(x))$

Будем искать init среди $w_{ij} \stackrel{iid}{\sim} \mathcal{N}(0, \text{Var}(w))$, с неизв. параметр. $\text{Var}(w)$

Хотим бы сохранили нормированность выборки.

При проходе вперёд:

$$\bullet \mathbb{E} z_i = 0$$

$$\bullet \text{Var}(z) = n_{in} \text{Var}(w) \text{Var}(x)$$

Также хотим нормиров. градиенты:

$$\Rightarrow \left. \begin{array}{l} \text{возникают требования:} \\ \text{Var}(z) = \text{Var}(x), \text{Var}(L'_x) = \text{Var}(L'_z) \end{array} \right| \Rightarrow \begin{cases} n_{in} \text{Var}(w) = 1 \\ n_{out} \text{Var}(w) = 1 \end{cases}$$

$$\bullet \mathbb{E}(L'_{x_i}) = 0$$

$$\bullet \text{Var}(L'_{x_i}) = n_{out} \text{Var}(w) \text{Var}(L'_z)$$

В качестве коимпреси можно взять: $\text{Var}(w) = \left[\frac{2}{n_{in} + n_{out}} \right]$
 Если $w_{ij} \stackrel{iid}{\sim} \left[-\frac{1}{n}, \frac{1}{n} \right]$, то $n = \frac{n_{in} + n_{out}}{6}$

Инициализация для tanh

1. $g(x) = -g(-x)$

2. $g'(0) = 1$

Хотим избежать затухания.

В кейот. предполож. оптимально взять:

$$\begin{cases} \text{IEW}^L = 0 \\ \text{IDW}^L = \frac{2}{n_{in} + n_{out}} \end{cases} \quad \text{либо} \quad \text{IDW}^L = \frac{1}{n^{L-1}} \quad \text{либо} \quad \text{IDW}^L = \frac{1}{n^L}$$

(для прямого прохода) (для обратного)

Также можно: $W_{ij}^L \sim \mathcal{U}\left[-\sqrt{\frac{6}{n_{in} + n_{out}}}, \sqrt{\frac{6}{n_{in} + n_{out}}}\right]$

Ортогональная

хотим столбцы W ортогональны $\Rightarrow$ для случ. $V \in \mathbb{R}^{d \times d}$
 $W = \exp(V - V^T)$ - ортогональна

Skip-connection

решает проблема:

- затухание
- потеря признаков
- сглаживание ландшафта ф-ии потерь

Drop Out

т.к. $y_i \sim \text{Bern}(1-p)$
 $a^{\text{almost D.O.}} := a \odot y \Rightarrow \mathbb{E} a^{\text{D.O.}} = (1-p) \mathbb{E} a$
 то кацо: $a^{\text{D.O.}} = \frac{a \odot y}{1-p}$

процедура устранист коадаптацию: когда верхние слои просто копируют прошлых и не учатся

Стохаст. оптим.

SGD не только оптимизирует веса, но и явл-ся в нек-ой степени регуляризатором, за счёт "шумного" градиента