

Оптимизация в DL

$$\min_w \frac{1}{n} \sum L(f_w(x_i), y_i) = L(w)$$

$$GD \rightarrow w^{t+1} = w^t - \eta \nabla L(w^t)$$

$O(ns)$ если не по батчу

$$SGD \rightarrow L^t = \frac{1}{B} \sum_{i=1}^B L(f_w(x_{i,t}), y_{i,t})$$

$O(Bs)$

$$i_t \sim U\{1, \dots, n\}$$

SGD + импульс

$$g^t = \nabla L^t(w^t)$$

$$m^t = \mu m^{t-1} + g^t \rightarrow \alpha m^t + (1-\alpha) g^t$$

$$w^{t+1} = w^t - \eta m^t$$

$\mu = 0,9$ обычно.



проблема
GD-осциляции
для таких поверхностей

$$L = L(w) = \mathbb{E}_{x,y \sim D} L(f_w(x), y) \approx \frac{1}{n} \sum_{i=1}^n L(f_w(x_i), y_i) = \frac{1}{n} \sum_{i=1}^n L_i(w) \rightarrow \min_w$$

Минусы SGD:

- Итерации не всегда уменьшают L , даже при маленьких ϵ , что может замедлить сходимость, но предотвратить застревание в локал. минимумах
- Сложнее определить критерий останова
- Добавляется гиперпараметр — B
- Дисперсия в оценке может не позволить сойтись при const темпе обуч.
- SGD будет „сходиться“ к области, называемой confusion region
- Выбор опт. темпа обуч. очень важен, чтобы соблюсти баланс между confusion region и ск-ю сх-ты

Верная оценка: $\|E\bar{w}^k - L(w^*)\| \leq \frac{R^2 + G^2 \sum_{i=1}^k \epsilon_i^2}{2 \sum_{i=1}^k \epsilon_i}$

$\bar{w}^k = \frac{\sum_{i=1}^k \epsilon_i w^i}{\sum_{i=1}^k \epsilon_i}$, $R = \|w^0 - w^*\|$ - началь. удален. от оптимальн

1. $\epsilon_i = \epsilon \quad \forall i$:

$\|E\bar{w}^k - L(w^*)\| \leq \frac{R^2}{2\epsilon(k+1)} + \frac{G^2 \epsilon}{2} \xrightarrow{k \rightarrow \infty} \frac{G^2 \epsilon}{2} \Rightarrow$ не можем варьир. ϵ -ом ϵ -ом
 размер confusion region $\propto \epsilon$

2. $\sum_{i=1}^k \epsilon_i \xrightarrow{k \rightarrow \infty} \infty, \sum_{i=1}^k \epsilon_i^2 < \infty$

Тогда $\|E\bar{w}^k - L(w^*)\| \xrightarrow{k \rightarrow \infty} 0 \quad \checkmark$. Однако следует выбирать такую ϵ чтобы макс ϵ -ом ϵ -ом

Adagrad:

$v^{t+1} = v^t + (g^t)^2$

$m^t = \frac{g^t}{\sqrt{v^t} + \epsilon}$

Для каждой координаты
регулируем скорость

$w^{t+1} = w^t - \eta_t m^t$

AMSprop

Чтобы не накапливался слишком v^t

$v^{t+1} = \beta v^t + (1-\beta) (g^t)^2$

$m^t = \frac{g^t}{\sqrt{v^t} + \epsilon}$

$w^{t+1} = w^t - \eta_t m^t$

Adam: $-||- + -||- + \text{bias correct}$

"Adam": RMS Prop + momentum

$m^t = \beta_1 m^{t-1} + (1-\beta_1) g^t \quad \cdot \frac{1}{1-\beta_1^t}$

$v^t = \beta_2 v^{t-1} + (1-\beta_2) (g^t)^2 \quad \cdot \frac{1}{1-\beta_2^t}$

$w^{t+1} = w^t - \eta_t \frac{m^t}{\sqrt{v^t} + \epsilon}$

Оценим погрешность $\|E$ и $\|v$

Почему сохраняем $\|m\|$ и $\|v\|$ и $\|g\|$ в Adam

1) For from optimum

$\|g\| \approx 0$

$\frac{\|g\|}{\sqrt{\|g\|^2 + \epsilon}} = \frac{\|g\|}{\sqrt{\|g\|^2 + \epsilon}} \approx 1$

a) Close to optimum

$$IDg \gg 0$$


$$\frac{IEg}{ID + (IEg)^2 + \epsilon} < 1$$



Хотим
уменьшить шаг

Таким образом шумные способы корректируются
шаги в Adam. То есть происходит как бы падение фриктивного η

Какой оптимумы хотим?



мы хотим
отвечать
на шум

а вот эту
уже отвечает
объекту


Чтобы избежать, берем сначала большой шаг,
а затем уменьшаем

Schedulers

$$1) \delta_t = \left(1 - \frac{t}{T}\right) \delta_0$$



$$2) \delta_t = \delta_0 e^{-at}$$

3) Cosine Annealing



$$\gamma_t = \gamma_{\min} + \frac{1}{2} (\gamma_{\max} - \gamma_{\min}) \left(1 + \cos \frac{t}{T} \right)$$

$[2, 0]$



4) Warmup scheduler

На практике работает лучше

Интуиция: на первых итерациях все коэф-ты пробное, нужно больше ~~итераций~~ итераций, чтобы разогреть параметры, поэтому можно быть осторожной начинать с меньшей learning rate

Weight Decay L_2 регуляризатор

$$\min_w \mathcal{L}(w) + \frac{\lambda}{2} \|w\|_2^2$$

одно и то же для SGD

$$w^{t+1} = w^t + \gamma_t (\nabla \mathcal{L}(w^t) + \lambda w^t) = w^t (1 - \gamma_t \lambda) - \gamma_t \nabla \mathcal{L}(w^t)$$

Weight decay

потому что буквально уменьшает вес

увеличивает эффектив. lr

$$w^{t+1} = (1 - \lambda') w^t - \gamma_t \nabla \mathcal{L}(w^t)$$

SGD + wd ↑

также wd масштабирует уровень шума в градиенте SGD относительно весов модели. имеет регуляриз. эффект

$$w^{t+1} = w^t (1 - \lambda') + \gamma_t \nabla \mathcal{L}(w^t)$$

Раскроем

$$w^{t+1} = w^t - \frac{\gamma_t}{1 - \beta_1} \beta_1 m^{t+1} + (1 - \beta_1) (g^t + \lambda w^t)$$

Adam

$$= \left(1 - \frac{\gamma_t (1 - \beta_1) \lambda}{(1 - \beta_1) (\gamma_t + \epsilon)} \right) w^t - \dots$$

Собираем weight decay и все, что было

$$= \left(1 - \frac{\lambda_i}{\sqrt{v^t} + \epsilon}\right) w^t - \dots$$


И получается для каждого веса свой weight decay, который уменьшается

Adam W — используется сейчас.


$$w^{t+1} = w^t - \delta_t \left(\frac{\hat{m}^t + \lambda w^t}{\sqrt{v^t} + \epsilon} \right)$$

и сложится у нас weight decay

Простой адеи ~~работает~~ ^{нужно} работать, потому что неправильно работает с wd



Нужно знать T



Этим удобнее делать checkpoints. Т.к. можно начать уменьшение с любой точки

sign SGP

$$w^{t+1} = w^t - \delta_t \nabla L(w^t) \rightarrow w^{t+1} = w^t - \delta_t \underbrace{\text{sgn}}_{\text{signum}}(\nabla L(w^t))$$

$$m^{t+1} = \mu m^t + g^t$$

$$w^{t+1} = w^t - \delta_t \text{sgn}(m^t)$$

Многие работают лучше Adam

СТАНДАРТ: AdamW + Warm Up

